

# 深層学習の源流


## 脳からパーセプトロンへ

Tatsuro Senga

Keio

# 神経細胞とその結合

甘利俊一, 1978, 神経回路網の数理



# 数理脳科学の視点

## 目的

深層学習の歴史と理論的進展を、**数理脳科学**の観点から概観する。

## 数理脳科学とは

生物学的現実性のみに固執せず、単純化された数理モデルを通じ、脳の情報処理における基本原理の理解を目指す学問分野である。

- 脳は進化の過程で形成された複雑なシステムであり、非効率な部分を含む可能性がある。
- そのため、本質的な原理を抽出し、知能や意識の起源を解明することが重要となる。
- 経済学のアプローチと似ているところがある。

# AIの黎明期：二つのアプローチ

AIの歴史は、大きく二つの異なる潮流から始まった。

## 1. 論理ベースのAI

- 1956年のダートマス会議が起源 (John McCarthy, Marvin Minsky, Claude Shannon, etc.).
- コンピュータを、論理推論を行うチューリングマシンと見なすアプローチ。
- Alan Turing, 1950, Computing Machinery and Intelligence.

## 2. 脳神経科学に触発されたAI

- 心理学者 **F. Rosenblatt** が提唱。
- 知能は神経回路の学習プロセスから生まれるという思想。
- パーセプトロンの開発へ繋がる。
- F. Rosenblatt, 1961, Principles of Neurodynamics.

# McCulloch-Pitts モデルからパーセプトロンへ

## McCulloch-Pitts モデル (1943)


- 脳神経科学に基づく、初のニューロン数学モデル。
- **仕組み**: 複数の二値入力 (0 or 1) を受け取り、その合計が固定のしきい値を超えた場合に 1 を出力する。
- **限界**: 重みやしきい値は手動で設定する必要がある、**学習する能力を持たない**。

## パーセプトロン (1961)

Rosenblatt が McCulloch-Pitts モデルに**学習則**を導入したモデル。

- **仕組み**: 複数の入力に**重み**を付け、その合計値が**しきい値**を超えると発火する。
- **学習**: 出力が誤っていた場合、その**誤りに基づいて重みを自動で調整**する。これにより、データから自動で分類境界を学習できるようになった。
- **能力**: 線形分離可能なパターンであれば、有限回の学習で必ず分類できる (収束定理)。

# 神経細胞とその結合



## 生物学的ニューロン：

- 複数の信号を受信
- 情報を統合
- 閾値を超えると発火

## 数学的モデル：

- 重み付き入力を合計
- バイアス項を追加
- 活性化関数を適用


出典：甘利俊一, 1978, 神経回路網の数理

## 特徴：

- ニューロンの最初の数学的モデル
- バイナリ入力（0 または 1）
- 固定閾値  $\theta$
- バイナリ出力
- 学習能力なし！

## 数学的形式：

$$y = \begin{cases} 1 & \text{if } \sum_i x_i \geq \theta \\ 0 & \text{otherwise} \end{cases}$$



# Rosenblatt のパーセプトロン

## 革命的特徴：

- 調整可能な重み！
- 学習アルゴリズム
- 収束定理
- 自動分類


## 数学的形式：

$$u = \sum_{i=1}^n w_i x_i + b$$

$$y = f(u)$$

## 学習ルール：

- 出力が正しい場合：何もしない
- 出力=0、正解=1：重みを増加
- 出力=1、正解=0：重みを減少





# パーセプトロンの限界：XOR問題

## ミンスキーとパパートによる批判 (1969)

Perceptrons: An Introduction to Computational Geometry (1969) で、単層パーセプトロンの数学的な限界を示した。

- **XOR問題**のような、**線形分離不可能**な問題は原理的に解けないことを示した。
- この批判は、ニューラルネットワーク研究の資金提供を停滞させ、「冬の時代」を招く一因となった。
- 他にも、パーセプトロンの学習則には、計算量が多く、実用的でないという問題があった。

# 実用例：Gitでのファイル差分検出

## 2つのバージョンの違いを見つける

### XORで差分検出

ファイル A: 1010

ファイル B: 1100

XOR 結果: 0110

結果の意味：

- 0 = 同じビット
- 1 = 異なるビット

→ 2番目と3番目のビットが変更された

### XORの真理値表

旧	新	XOR	意味
0	0	0	変更なし
0	1	1	変更あり
1	0	1	変更あり
1	1	0	変更なし

git diff の基本原理

(実際はもっと複雑ですが、  
差分検出の基本は XOR)

問題：このパターンをニューラルネットワークで学習できるか？

# Minsky & Papert の批判 (1969 年)


**XOR 真理値表：**

$x_1$	$x_2$	出力
0	0	0
0	1	1
1	0	1
1	1	0

**問題：**

単一の線でクラスを分離できない！

XOR は線形分離不可能



# 数学的な矛盾 (The Mathematical Contradiction)

パーセプトロンの出力は、 $w_1x_1 + w_2x_2 + b$  の符号による。

出力 1 を「 $> 0$ 」、出力 0 を「 $\leq 0$ 」と仮定すると、4 つの条件が生まれます。

- ① 入力 (0, 0) → 0:  $w_1(0) + w_2(0) + b \leq 0 \implies b \leq 0$
- ② 入力 (0, 1) → 1:  $w_1(0) + w_2(1) + b > 0 \implies w_2 + b > 0$
- ③ 入力 (1, 0) → 1:  $w_1(1) + w_2(0) + b > 0 \implies w_1 + b > 0$
- ④ 入力 (1, 1) → 0:  $w_1(1) + w_2(1) + b \leq 0 \implies w_1 + w_2 + b \leq 0$

## 矛盾 (Contradiction)

- 条件 2 から  $w_2 > -b$ 。
- 条件 3 から  $w_1 > -b$ 。
- この 2 つを足すと:  $w_1 + w_2 > -2b$


しかし、条件 4 は  $w_1 + w_2 \leq -b$  を要求。

これらの条件を同時に満たす重み ( $w_1, w_2$ ) とバイアス ( $b$ ) は存在しない。

# 複数の直線を組み合わせる

## 2層ネットワークの戦略：

2つの直線で領域を分割



## 隠れ層の役割：

### ① ニューロン 1：

$$h_1 = f(x_1 - x_2 + 0.5)$$

左上を検出

### ② ニューロン 2：

$$h_2 = f(x_1 - x_2 - 0.5)$$

右下を検出

### ③ 出力層：


$$y = f(h_1 - h_2)$$

中間領域を抽出！

## 隠れ層

複数の線形境界を組み合わせ  
て非線形な決定境界を作成

# ネットワークの構造と計算ルール



## 3層構造

- 入力層 ( $x_1, x_2$ ): データを受け取る
- 中間層 ( $a_1, a_2$ ): 入力を新表現に変換
- 出力層 ( $r$ ): 最終的な答えを出力

# XOR問題の真偽表

## XOR問題の真偽表

入力層		中間層		出力層
$x_1$	$x_2$	$a_1$	$a_2$	$r$
0	0	0	1	0
0	1	1	1	1
1	0	1	1	1
1	1	1	0	0

## 計算式

- $a_1 = x_1 \times 1 + x_2 \times 1 - 0.5$
- $a_2 = x_1 \times -1 + x_2 \times -1 + 1.5$
- $r = a_1 \times 1 + a_2 \times 1 - 1.5$

## 計算結果

- 1: 入力  $(x_1, x_2)=(0, 0) \rightarrow (a_1, a_2)=(0, 1) \rightarrow$  出力  $r: 0$
- 2: 入力  $(x_1, x_2)=(0, 1) \rightarrow (a_1, a_2)=(1, 1) \rightarrow$  出力  $r: 1$
- 3: 入力  $(x_1, x_2)=(1, 0) \rightarrow (a_1, a_2)=(1, 1) \rightarrow$  出力  $r: 1$
- 4: 入力  $(x_1, x_2)=(1, 1) \rightarrow (a_1, a_2)=(1, 0) \rightarrow$  出力  $r: 0$

## 具体的な計算の流れ (1/2)

### ケース 1：入力 (0, 0)

- $a_1$ :  
 $(0 \times 1) + (0 \times 1) - 0.5 = -0.5 \rightarrow 0$
- $a_2$ :  $(0 \times -1) + (0 \times -1) + 1.5 = 1.5 \rightarrow 1$
- $r$ :  
 $(0 \times 1) + (1 \times 1) - 1.5 = -0.5 \rightarrow 0$

最終出力: 0

### ケース 2：入力 (0, 1)

- $a_1$ :  
 $(0 \times 1) + (1 \times 1) - 0.5 = 0.5 \rightarrow 1$
- $a_2$ :  $(0 \times -1) + (1 \times -1) + 1.5 = 0.5 \rightarrow 1$
- $r$ :  
 $(1 \times 1) + (1 \times 1) - 1.5 = 0.5 \rightarrow 1$

最終出力: 1



## 具体的な計算の流れ (2/2) と結論

### ケース3：入力 (1, 0)

- $a_1$ :  
 $(1 \times 1) + (0 \times 1) - 0.5 = 0.5 \rightarrow 1$
- $a_2$ :  $(1 \times -1) + (0 \times -1) + 1.5 = 0.5 \rightarrow 1$
- $r$ :  
 $(1 \times 1) + (1 \times 1) - 1.5 = 0.5 \rightarrow 1$

最終出力: 1

### ケース4：入力 (1, 1)

- $a_1$ :  
 $(1 \times 1) + (1 \times 1) - 0.5 = 1.5 \rightarrow 1$
- $a_2$ :  $(1 \times -1) + (1 \times -1) + 1.5 = -0.5 \rightarrow 0$
- $r$ :  
 $(1 \times 1) + (0 \times 1) - 1.5 = -0.5 \rightarrow 0$


最終出力: 0

### 中間層が役立つ

もとの入力 ( $x_1, x_2$ ) は線形分離不可能だったが、中間層がそれらを新しい表現 ( $a_1, a_2$ ) に変換した。この新しい特徴空間では、問題が線形分離可能になっている。

# 3層ネットワークがXORを解決

ネットワーク構造：



入力

隠れ層

出力

計算：

- $a_1 = x_1 + x_2 - 0.5$
- $a_2 = -x_1 - x_2 + 1.5$
- $r = a_1 + a_2 - 1.5$

検証：

$x_1$	$x_2$	$a_1$	$a_2$	$r$
0	0	0	1	0
0	1	1	1	1
1	0	1	1	1
1	1	1	0	0

完璧な XOR 計算！

# 中間層学習の基礎：確率的勾配降下法

歴史的発展：今日の最適化手法の基礎は 1950-60 年代に

- **Robbins-Monro (1951)**: 確率的近似法 (0)
- **Kiefer-Wolfwitz (1952)**: 確率的近似法 (最小値)

これらの**確率的近似法**は、ノイズを含むデータから関数の最小値を逐次的に見つける手法の基礎を築いた。

# 中間層学習の基礎：アナログパーセプトロンへの応用

多層パーセプトロンの中間層学習則として、オンライン確率的勾配降下法を提案 (ノンパラメトリックな学習法)

- Amari, 1966, 1967
- Tsypkin, 1966

$$y = f(x, \theta) + \varepsilon$$

$$\text{Loss: } \ell(x, \theta) = \frac{1}{2} \{y - f(x, \theta)\}^2$$

$$\text{Learning: } \Delta\theta = -\eta \frac{\partial \ell(x, \theta)}{\partial \theta}$$

アナログパーセプトロンは連続変数なので微分可能

収束の証明、精度、速度についても証明



情報科学講座 A.2.5



# 情報理論 II

—情報の幾何学的理論—

北川敏男 編

## 第 5 章 学習識別の理論

5.1 学習識別系.....110

5.2 確率的降下法による学習 .....113

5.3 学習の速度, 精度, 動特性.....126

.....あとがき.....136

.....参考文献.....137

.....索引.....1~3

# 確率的降下法（確率的近似法の応用）

- 損失関数  $\ell(x, \theta)$  を最小化したい。しかし  $\ell(x, \theta)$  は未知。
- $\theta' = \theta + \Delta\theta$  とすると、 $\ell(x, \theta)$  が「平均」として減少するように  $\Delta\theta$  を選ぶ。
- これは、坂の途中に立たされた「よっばらい」が酔歩を行なう状況に似ている。彼は、あるときは山を登る方向によろめき、また次には山を下る方向によろける。登る確率よりは下る確率のほうが大きいので、彼は平均としては山をずり落ちて行き、ついには谷底へ落ち込む。そして谷底の近傍で、よろめき（微小振動）を続けるであろう。（甘利, 1968）

# 深層学習の夜明け：誤差逆伝播法

「冬の時代」は、1980年代に**誤差逆伝播法 (Backpropagation)** が再発見・普及したことで終わりを告げる。

## 誤差逆伝播法 (PDP) とは？

多層ニューラルネットワークを効率的に訓練するアルゴリズム。

- **仕組み**: 損失関数に対する勾配を、出力層から入力層へ効率的に計算する。
- **重要性**: これにより中間層の学習が可能となり、深層学習の発展の礎となった。

## 主な貢献者

- **Rumelhart, Hinton, Williams (1986)**: PDP(Parallel Distributed Processing) として広く普及させた。
- **Amari (1966), Tsybkin (1966), Werbos (1974)**: それ以前に同様のアイデアを独立して発表。



# 深層学習ブーム (2012年～)

現在のブームは、2012年の **ImageNet コンペティション**での歴史的な勝利がきっかけとなった。

## ブームの要因

- 計算能力の向上: GPU の活用。
- ビッグデータ: 大規模な訓練データセットの利用。
- 技術革新: より深いアーキテクチャや正則化技術の開発。

## 主な応用分野

- 画像認識
- 音声認識
- 自然言語処理

## 深層学習の課題

データから「実験式」を見つけるのは得意だが、その背後にある根本原理を理解する能力はまだない。

# 最近の理論的展望：深層学習の謎

深層学習の成功は、従来の統計的学習理論では説明が難しい現象を伴う。

## 謎1：過学習の問題

- **従来の理論**: パラメータ数がデータ数を上回ると、過学習が起きるとされた（U字カーブ現象）。
- **深層学習の現実**: パラメータ数がデータ数をはるかに超えても、高い汎化性能を示す。

## 謎2：局所最適解の問題

- **従来の懸念**: 巨大なパラメータ空間には多数の局所最適解が存在し、学習が停滞すると考えられていた。
- **深層学習の現実**: 実際には、局所最適解が問題になることは少なく、多くの場合で性能の良い解に到達する。